


# 人工知能概論第 3 回

今村耕介

# 先週のお話

- ID3 決定木
- 分類/識別方法：エントロピーを低くする質問を繰り返し、エントロピーの低いグループに到達する。

# ID3




エントロピー

=

$$-\{(1/9) \cdot \log_2(1/9) + (4/9) \cdot \log_2(4/9) + 4/9 \cdot \log_2(4/9)\}$$


# ID3




エントロピー

```
import math  
-{(1/9)*math.log2(1/9) + (4/9)*math.log2(4/9) + 4/9*math.log2(4/9)}
```

# ID3



# ID3



# 情報利得 (Information Gain)

- $IG(D, A) = H(D) - H(D|A)$

# 課題ID3データ

| • Outlook     | temp | humidity | wind   | play |
|---------------|------|----------|--------|------|
| • 0 Sunny     | Hot  | High     | Weak   | No   |
| • 1 Sunny     | Hot  | High     | Strong | No   |
| • 2 Overcast  | Hot  | High     | Weak   | Yes  |
| • 3 Rain      | Mild | High     | Weak   | Yes  |
| • 4 Rain      | Cool | Normal   | Weak   | Yes  |
| • 5 Rain      | Cool | Normal   | Strong | No   |
| • 6 Overcast  | Cool | Normal   | Strong | Yes  |
| • 7 Sunny     | Mild | High     | Weak   | No   |
| • 8 Sunny     | Cool | Normal   | Weak   | Yes  |
| • 9 Rain      | Mild | Normal   | Weak   | Yes  |
| • 10 Sunny    | Mild | Normal   | Strong | Yes  |
| • 11 Overcast | Mild | High     | Strong | Yes  |
| • 12 Overcast | Hot  | Normal   | Weak   | Yes  |
| • 13 Rain     | Mild | High     | Strong | No   |



# プログラミングヒント

- C :
  - `#define Sunny 1`
  -
- JAVA:
  - `public class Constants {`
  - `public static final int SUNNY = 1;`
  - `}`
  - `Constants.SUNNY;`
  -
- Python:
  - `SUNNY = 1`



ところで、教師あり、教師なしについて：

1．病気かどうかを判別するアルゴリズムを機械学習させる場合，教師データ(病気かどうかのデータ)を使う教師あり学習


2．商品を顧客を購入履歴をもとにグループ化したいが、正解のグループというのはあらかじめわかっていないので教師なし学習

では、先週勉強した ID3は 教師  
有るか、教師無しか？


# kNN (k Nearest Neighbor) k最近傍法

- 教師なしの機械学習アルゴリズムの一つ

# クラスタリング(clustering)




- グループ化（クラスター）
- クラスタリングに教師無し学習があります。
- あとで、これを勉強します。。。。。



*hard*

ハード：明確



*soft*

ソフト：不明瞭

さて、6は、どの色にする？

1 2 3 4 5 6 7 8 9 10 11 12

1 2 3

8

11 12

6



さて、6は、どの色にする？

1 2 3 4 5 6 7 8 9 10 11 12

1 2 3

8

11 12


<-----6----->

k=1

<-----6----->


k=3

# 属性が2つあるときは？




$$a^2 + b^2 = c^2$$

$$c = \sqrt{a^2 + b^2}$$




赤ワイン白ワイン：ミリセチン Myricetin、ルチンRutine



# 赤ワインか、白ワインか

Five neighbours. Four  
red and one white

K=5



属性が  $n$  個あるときは、 、 、

$$\begin{aligned} d(p, q) &= d(q, p) \\ &= \sqrt{(q_1 - p_1)^2 + (q_3 - p_3)^2 + \cdots + (q_n - p_n)^2} \\ &= \sqrt{\sum_{i=1}^n (q_i - p_i)^2} \end{aligned}$$

# 注意点

## 正規化 (Normalization)

## 標準化 (Standardization)


使用する際の注意点: 外れ値。非常に大きな値や小さな値が外れ値として存在していた場合、注意する必要があります。

例:

2,4,4,6,6,8,1,1,3,2,4,1000      平均=86.75

2,4,4,6,6,8,1,1,3,2,4,3          平均= 3.67

# 外れ値





# オリジナルデータ

<https://www.codexa.net/normalization-python/>

■表A

| 生徒 | 身長(cm) | 平熱(°C) |
|----|--------|--------|
| A  | 168    | 37.1   |
| B  | 170    | 36.3   |
| C  | 168    | 35.6   |
| D  | 162    | 36.1   |
| E  | 182    | 36.1   |

# 機械学習の前処理

## 「正規化」と「標準化」

# 正規化

$$x_{norm}^i = \frac{x^i - x_{min}}{x_{max} - x_{min}}$$

$x^i$  特徴量内の各値

$x_{min}$  特徴量内の最小値

$x_{max}$  特徴量内の最大値

8 2 3 6 1

8 --> (8-1)/(8-1) = 1.0

2 --> (2-1)/(8-1) = 1/7

3 --> (3-1)/(8-1) = 2/7

...

1 --> (1-1)/(8-1) = 0.0

# 標準化

$$x_{std}^i = \frac{x^i - u}{\sigma}$$

$x^i$  特徴量内の各値

$u$  特徴量内の平均値

$\sigma$  特徴量内の標準偏差

例：データが8 2 3 6 1のとき、

平均  $u = 20/5$  , 標準偏差  $\sigma = 2.61$

8 -->  $(8 - 4)/2.61$

2 -->  $(2 - 4)/2.61$

3 -->  $(3 - 4)/2.61$

...

1 -->  $(1 - 4)/2.61$

## A:オリジナル

■表A

| 生徒 | 身長(cm) | 平熱(°C) |
|----|--------|--------|
| A  | 168    | 37.1   |
| B  | 170    | 36.3   |
| C  | 168    | 35.6   |
| D  | 162    | 36.1   |
| E  | 182    | 36.1   |

## B:標準化

■表B

| 生徒 | 身長(cm) | 平熱(°C) |
|----|--------|--------|
| A  | -0.304 | 1.761  |
| B  | 0      | 0.123  |
| C  | -0.304 | -1.311 |
| D  | -1.217 | -0.287 |
| E  | 1.826  | -0.287 |


$$\text{A-C間のユークリッド距離} = 1.5 = \sqrt{(168 - 168)^2 + (35.6 - 37.1)^2}$$

$$\text{D-E間のユークリッド距離} = 20 = \sqrt{(182 - 162)^2 + (36.1 - 36.1)^2}$$


$$\text{A-C間のユークリッド距離} = 3.072 = \sqrt{\{(-0.304) - (-0.304)\}^2 + \{(1.761) - (-1.311)\}^2}$$

$$\text{D-E間のユークリッド距離} = 3.043 = \sqrt{\{(-1.217) - (1.826)\}^2 + \{(-0.287) - (-0.287)\}^2}$$


# データ不均衡




# SMOTE (Synthetic Minority Over-sampling Technique)



# SMOTE (Synthetic Minority Over-sampling Technique)







# KNNの擬似コード (pseudocode)

1. データ読み込み
2.  $K$  の値を決定
3. 各データポイントにつき:
  - ユークリッド距離をすべてのポイントについて計算
  - 距離の短い順に保存
4. 上位  $k$  を選択し多数決
5. おわり

# 練習問題

- あなたは、百万遍コーヒー店の社長です。大阪コーヒーのセールスマンが苦味 6，酸味 4 のコーヒーを売りに来ました。このコーヒーが売れるかどうかを予測し、買うか買わないかを過去の苦味、酸味、販売データにもとづいて決めてください。

（2023年、春学期の期末テスト問題）

# 分析データが正規化されている場合

|         | 苦味 | 酸味 | 販売 |
|---------|----|----|----|
| coffee1 | 7  | 6  | 好調 |
| coffee2 | 6  | 6  | 好調 |
| coffee3 | 4  | 5  | 不調 |
| coffee4 | 6  | 7  | 好調 |
| coffee5 | 3  | 7  | 不調 |
| coffee6 | 7  | 4  | 不調 |
| coffee7 | 5  | 5  | 好調 |

大阪coffee 6 4 ?

注：0.0～1.0の間ではありませんが、0.7、0.6、0.4...を10倍すると、それぞれ7, 6, 4,...となります。すべてのデータにある数を掛けても割っても距離関係は変わりません。

# 計算の仕方

|          | 苦味                  | 酸味   | 距離 | 販売 |
|----------|---------------------|------|----|----|
| coffee1  | $(7-6)^2 + (6-4)^2$ | = d1 | 好調 |    |
| coffee2  | $(6-6)^2 + (6-4)^2$ | = d2 | 好調 |    |
| coffee3  | $(4-6)^2 + (5-4)^2$ | = d3 | 不調 |    |
| coffee4  | $(6-6)^2 + (7-4)^2$ | = d4 | 好調 |    |
| coffee5  | $(3-6)^2 + (7-4)^2$ | = d5 | 不調 |    |
| coffee6  | $(7-6)^2 + (4-4)^2$ | = d6 | 不調 |    |
| coffee7  | $(5-6)^2 + (5-4)^2$ | = d7 | 好調 |    |
| 大阪coffee | 6                   | 4    | ?  |    |

ソート  $d_i$  距離の短い順

上位  $k$  を選択し多数決 (好調、不調)

## 課題 4 データを正規化してからKNNしてください

|        | 温度 | 湿度 | カビ |
|--------|----|----|----|
| Kyoto  | 40 | 4  | Y  |
| Mito   | 30 | 3  | N  |
| Tokyo  | 50 | 3  | N  |
| Nagoya | 60 | 5  | Y  |
| Nara   | 60 | 6  | Y  |
| Kobe   | 50 | 6  | Y  |
| Himeji | 60 | 4  | Y  |
| Kofu   | 50 | 4  | N  |

Yaizu      40      5      ?

K=1    \_\_\_\_\_

K=3    \_\_\_\_\_