

人工知能概論第 5 回

k 平均法

京都情報大学院大学 今村耕介

k NN :

教師あり学習モデル

k 平均法:

教師なし学習モデル

K 平均法クラスタリング

- データ解析 / 機械学習
- 類似性の高いデータをグループ化: データの構造やパターンを見つける
- データセットを K 個のクラスタに分割する
- 簡単かつ効率的な方法


K 平均法

- データポイント間の類似性を測るために距離尺度を使用。一般的にはユークリッド距離。他の距離尺度も適用可能。
- 方法：各クラスタ内のデータポイント間の距離の総和（クラスタ内平方和）を最小化する。これにより、類似性の高いデータポイントが同じクラスタに分類される。

K 平均法の応用


- マーケティング分析：顧客データを顧客グループ化し、ターゲティングやプロモーション戦略を最適化、
-

教師なし学習のモデル




kNN 復習

- 距離
- $k = 3$
- $k = 5$
- 多数決




kNN 復習

- 距離
- $k = 3$
- $k = 5$
- 多数決
- A, B どちら?




変形 kNN 法 (modified kNN)

- 近い距離により大きい重みを付ける
- $w_1 > w_2$
- どのような重みの付け方が考えられますか?




- 距離
- $k = 3$
- $k = 5$
- どっち?



教師なし学習のモデル

教師なし学習「クラスタリング」



Kmeans (K 平均法) とは、

教師なし学習：教師データは無い。――> **正解がない。**




データ間の類似度の尺度を決める（例、体積、温度、酸度、融点、所得、加速度、。。。）

データ間の類似度の尺度は距離と呼ばれます。

距離が近いほど類似度が高い。

距離が遠いほど類似度が低い。

距離の種類：データの性質に従って選ぶ。代表的な距離にはユークリッド距離。




k- 平均法


1. 「何個のクラスタに分けるか」を設定する
 2. ランダムにクラスタの「代表点」を設定する
 3. データと代表点の「距離」を計算し、距離が最も近い代表点のクラスタにデータを所属させる
 4. クラスタの「重心」を新たな「代表点」とする
- (3)(4) を繰り返す

二つのクラスタに分けてみましょう

属性の解らないデータを分割する




ランダムにクラスタの「中心点（平均点）」を設定




$$((px0-Ax)**2 + (py0-Ay)**2) < ((px0-Bx)**2 + (py0-By)**2) \Rightarrow A \supset P0$$

中心点との距離を計算してクラスタ分け





$$((px0-Ax)**2 + (py0-Ay)**2) < ((px0-Bx)**2 + (py0-By)**2) \Rightarrow A \supset P0$$

クラスタ分けが終わったら中心を再計算




クラスタ分けが終わったら中心を再計算してグループ化




(1) 「何個のクラスタに分けるか」を設定する

2つのクラスタに分ける



(2) ランダムにクラスタの「代表点」を設定する





(3) データと代表点の「距離」を計算し、距離が最も近い代表点のクラスターにデータを所属させる


距離 = $\|X_n - \mu_k\|$ を求める



距離が近い方の代表点に所属させる




(4) クラスタの「重心」を新たな代表点とする




(5) (3) (4) を繰り返す

クラスタの分け方がまだ不適當





分け方が不適當であることは、どうしてわかりますか？


終了? (いつ終了?)



注意点







k 平均法 (k-means) 、 k 近傍法

- k 平均法 (k-means) 、 k 近傍法 (k-NN, k-nearest neighbor algorithm)
- 名前は似てる、、、
- k 平均法は教師なし学習
- k 近傍法は教師あり学習
- いずれも、データの前処理として特徴量の正規化や標準化

例題演習

1 次元の例：

データはクラス分けされていない

1 2 3 7 8 10 11 12

- クラスタ-数を 3 (赤、青、緑) としてみる。
- 中心をそれぞれ, x, y, z とする。
- 適当に、 x 、 y 、 z を決める。

x y z

4 5 10

1 2 3 7 8 10 11 12

x y z
4 5 10

1 2 3 7 8 10 11 12

(1 - x)² = 9, (1 - y)² = 16, (1 - z)² = 81; X={1}

(2 - x)² = 4, (2 - y)² = 9, (2 - z)² = 64; X={1,2}

(3 - x)² = 1, (3 - y)² = 4, (3 - z)² = 49; X={1,2,3}

(7 - x)² = 9, (7 - y)² = 4, (7 - z)² = 9; Y={7}

(8 - x)² = 16, (8 - y)² = 9, (8 - z)² = 4; Z={8}

(10 - x)² = 36, (10 - y)² = 25, (10 - z)² = 0; Z={8,10}

(11 - x)² = 49, (11 - y)² = 36, (11 - z)² = 1; Z={8,10,11}

(12 - x)² = 64, (12 - y)² = 49, (12 - z)² = 4; Z={8,10,11,12}

x y z
4 5 10

1 2 3 7 8 10 11 12

New Means:

$X=\{1, 2, 3\}$, $Y=\{7\}$, $Z=\{8, 10, 11, 12\}$

$$\begin{aligned} & \quad \quad \quad 2 \quad \quad \quad \quad \quad \quad 7 \quad \quad \quad 10.25 \\ (1-x)^2 &= \underline{1}, \quad (1-y)^2 = \frac{7}{36}, \quad (1-z)^2 = 85.6; \quad X=\{1\} \\ (2-x)^2 &= \underline{0}, \quad (2-y)^2 = 25, \quad (2-z)^2 = 68.1; \quad X=\{1,2\} \\ (3-x)^2 &= \underline{1}, \quad (3-y)^2 = 16, \quad (3-z)^2 = 52.3; \quad X=\{1,2,3\} \\ (7-x)^2 &= 25, \quad (7-y)^2 = \underline{0}, \quad (7-z)^2 = 10.6; \quad Y=\{7\} \\ (8-x)^2 &= 36, \quad (8-y)^2 = \underline{1}, \quad (8-z)^2 = 5.1; \quad Y=\{7,8\} \\ (10-x)^2 &= 64, \quad (10-y)^2 = 9, \quad (10-z)^2 = \underline{0.1}; \quad Z=\{10\} \\ (11-x)^2 &= 81, \quad (11-y)^2 = 16, \quad (11-z)^2 = \underline{0.6}; \quad Z=\{10,11\} \\ (12-x)^2 &= 100, \quad (12-y)^2 = 25, \quad (12-z)^2 = \underline{3.1}; \quad Z=\{10,11,12\} \end{aligned}$$

x y z
2 7.5 11

$(1 - x)^2 = 1, (1 - y)^2 = 42.3, (1 - z)^2 = 100; X=\{1\}$
 $(2 - x)^2 = 0, (2 - y)^2 = 30.3, (2 - z)^2 = 81; X=\{1,2\}$
 $(3 - x)^2 = 1, (3 - y)^2 = 20.3, (3 - z)^2 = 64; X=\{1,2,3\}$
 $(7 - x)^2 = 25, (7 - y)^2 = 0.3, (7 - z)^2 = 16; Y=\{7\}$
 $(8 - x)^2 = 36, (8 - y)^2 = 0.3, (8 - z)^2 = 9; Y=\{7,8\}$
 $(10 - x)^2 = 64, (10 - y)^2 = 6.3, (10 - z)^2 = 1; Z=\{10\}$
 $(11 - x)^2 = 81, (11 - y)^2 = 12.3, (11 - z)^2 = 0; Z=\{10,11\}$
 $(12 - x)^2 = 100, (12 - y)^2 = 20.3, (12 - z)^2 = 1; Z=\{10,11,12\}$

x	y	z	
2		7.5	11
1 2 3	7 8	10 11 12	

課題 3

あなたは、百万遍コーヒー店の社長です。K 平均法を使って以下のコーヒーを2つのグループ（クラスター）に分けなさい。**データは、規格化すること！**

分析

	苦味	酸味

coffee1	73	6
coffee2	60	6
coffee3	48	5
coffee4	65	7
coffee5	30	7
coffee6	78	4
coffee7	51	5

課題 3

あなたは、百万遍コーヒー店の社長です。K 平均法を使って以下のコーヒーを2つのグループ（クラスター）に分けなさい。**データは、規格化すること！**

分析

	苦味	酸味

coffee1	73	6
coffee2	60	6
coffee3	48	5
coffee4	65	7
coffee5	30	7
coffee6	78	4
coffee7	51	5

役に立つ PYTHON コード

https://www.programiz.com/python-programming/online-compiler/

← → ↺ 🏠  programiz.com/python-programming/online-compiler/

   ⋮

 ethernet  Gmail  YouTube  コンテンツ  Main Menu 

 All Bookmarks

Programiz
Python Online
Compiler

 **monday.com**

マルチプロダ
クトの登場！



monday work
management



monday
sales CRM



monday
dev

もっと詳しく

Programiz PRO
>



main.py



Save

Run

Output

Clear

```
1 d = [3,4,5,6,7]
2 sum=0
3 maximum= max(d)
4 minimum= min(d)
5 print('max=', maximum, ' min= ', minimum)
6 maxmindist = maximum - minimum
7 for i in d:
8     normalized = (i-minimum)/maxmindist
9     print('normalized ', i, ' => ', normalized)
10
11 print('-----')
12
13 center0 = [0.9,0.9]
```

```
max= 7   min= 3
normalized 3  =>  0.0
normalized 4  =>  0.25
normalized 5  =>  0.5
normalized 6  =>  0.75
normalized 7  =>  1.0
-----
averavge= 5.0
-----
dist0= 1.2200000000000002   dist1= 1.165
1
dist0= 14.020000000000001   dist1= 14.364999999999998
0
-----
```

```
center0 = [0.50,0.25]
center1 = [0.75,0.95]
sum=0
count=0
for i in d:
    sum = sum+i
    count= count+1
print('averavge= ', sum/count)

print('-----')
```

```
d = [3,4,5,6,7]
sum=0
maximum= max(d)
minimum= min(d)
print('max=', maximum, ' min= ', minimum)
maxmindist = maximum - minimum
for i in d:
    normalized = (i-minimum)/maxmindist
    print('normalized ', i, ' => ', normalized)

print('-----')
```

$$BX_u = (x_1 + x_2 + x_3 + \dots + x_6) / 6, \quad BY_u = (y_1 + y_2 + y_3 + \dots + y_6) / 6$$

```

. d = [3,4,5,6,7]
. sum=0
. maximum= max(d)
. minimum= min(d)
. print('max=', maximum, ' min=', minimum)
. maxmindist = maximum - minimum
. for i in d:
.     normalized = (i-minimum)/maxmindist
.     print('normalized ', i, ' => ', normalized)
.
. print('-----')
.
. center0 = [0.50,0.25]
. center1 = [0.75,0.95]
.
. sum=0
. count=0
. for i in d:
.     sum = sum+i
.     count= count+1
. print('average= ', sum/count)
.
. print('-----')
.
. # 以下、データポイント
. twodim = [[1,2],
.           [3,4],
.           [5,6],
.           [7,8],
.           ]
.
.
.
. for i in twodim:
.     #print(i[0], center0[0], i[1], center0[1])
.     #print((i[0]-center0[0]), (i[1]-center0[1]))
.     #print((i[0]-center0[0])**2+(i[1]-center0[1])**2)
.     #print((i[0]-center1[0])**2+(i[1]-center1[1])**2)
.     dist0=(i[0]-center0[0])**2+(i[1]-center0[1])**2
.     dist1=(i[0]-center1[0])**2+(i[1]-center1[1])**2
.     print('dist0=', dist0, ' dist1=', dist1)
.     if dist0<dist1:
.         print(0)
.     else:
.         print(1)

```